

Bayesian Decision

① $P(H|X) = \frac{P(H) \cdot P(X|H)}{P(X)}$

直接判断。

② $X, \Omega, A, \lambda \rightarrow$ 损失。

$R(\alpha_i|X) = \sum_{j=1}^c \lambda(\alpha_i|w_j) \cdot P(w_j|X)$

\Rightarrow Bayes decision rule: 损失小的选。

$\alpha(X) = \underset{\alpha \in A}{\operatorname{argmin}} R(\alpha|X)$

分类问题中 α_i 为分类的类别。

二分类: $R(\alpha_1|X) < R(\alpha_2|X) \Leftrightarrow \lambda_{21} \cdot P(w_1|X) < \lambda_{12} \cdot P(w_2|X)$

$\Leftrightarrow \frac{P(X|w_1)}{P(X|w_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \cdot \frac{P(w_2)}{P(w_1)}$

多分类:

使用 0-1 损失时: 对 0 错 1。

$R(\alpha_i|X) = 1 - P(w_i|X)$

$\sum_{j=1}^c \lambda(\alpha_i|w_j) \cdot P(w_j|X)$

w_i if $P(w_i|X) > P(w_j|X)$

高斯分布: $X \sim N(\mu, \sigma^2)$

$P(X) = \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{1}{2}(\frac{X-\mu}{\sigma})^2}$

$E[X] = \int_{-\infty}^{+\infty} x P(X) = \mu$

$\operatorname{Var}[X] = \int_{-\infty}^{+\infty} (x-\mu)^2 \cdot P(X) = \sigma^2$

\downarrow

针对 Gaussian 的判别函数推理 (P28)

$\begin{cases} \beta_1 = \beta_2 \rightarrow \text{linear} \\ \beta_1 \neq \beta_2 \rightarrow \text{quadratic} \end{cases}$

$\beta_1 = \text{arbitrary} \rightarrow \text{quadratic}$

$g_i(x) = \ln P(x|w_i) + \ln P(w_i)$

$\Leftrightarrow g_i(x) = -\frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1}(x-\mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(w_i)$

Parametric Estimation

Maximum Likelihood

① $P(w_j) \rightarrow$ count.

② $P(x|w_j) \rightarrow$ 假设服从某一分布

$\Rightarrow P(D|\theta) = \prod_{k=1}^n P(x_k|\theta)$

$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} P(D|\theta)$

求解: ① 加上 λ ② 对 θ 求导为 0 ③ 检查极值点哪个最优

应用: Gaussian $\begin{cases} \text{已知 } \Sigma, \text{ 估计 } \mu \\ \Sigma, \mu \text{ 未知} \end{cases}$ P10

$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n x_k$

$\hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})(x_k - \hat{\mu})^T$

Bayesian Estimation:

求 $P(w_j|x, D^*)$

\Rightarrow 每个类的后验, 最大的即结果 \Rightarrow 可能类别的

$P(w_j|x, D) = \frac{P(w_j) \cdot P(x|w_j, D)}{\sum_i P(w_i) \cdot P(x|w_i, D)}$

乘法公式 + 条件概率

求解: P74 高斯情况,

求 $P(\mu|D)$

① $P(x|D) = \int P(x|\theta) P(\theta|D) d\theta$

② $P(\theta|D) = \frac{P(\theta) P(D|\theta)}{\sum_k P(x_k|\theta) P(\theta)}$

递归 P79.

看题目, 按公式 + 化简.

HMM:

Notations:

① $\Omega = \{w_1, \dots\} \Rightarrow$ state

② $V = \{v_1, \dots\} \Rightarrow$ signal/symbol

③ $W^T = \{w_1, \dots\} \Rightarrow$ state sequence

④ $V^T = \{v_1, \dots\} \Rightarrow$ symbol sequence

⑤ A, B, π

$\pi_j = P(w_1 = w_j)$

Evaluation: P108

求 $P(V^T|\theta)$

前向 forward: \Rightarrow 记得求和, 从开始

后向 backward: \Rightarrow 记得求和, 从开始

$F: d_j(t) = [\sum_{i=1}^I a_{ij}(t-1) b_j(v_t)] b_j(v_t)$

$B: b_j(t) = \sum_{i=1}^I \pi_i a_{ij}(t) b_j(v_t)$

建议列表做。

Decoding: 求 $w^T, \max P(w^T|\theta, V^T) = \sum_j \pi_j b_j(v_1)$

① Viterbi

$\delta_j(t) = \max_{w_1, \dots, w_{t-1}} P(w_1, \dots, w_{t-1}, w_t = w_j, v_1, \dots, v_t|\theta)$

\Rightarrow 到 t 的前面 state/symbol 最高的概率 ($w_t = w_j$ 时)

\Rightarrow 求解: $\delta_j(1) = \pi_j b_j(v_1), \psi_j(1) = 0$

$\delta_j(t) = [\max_i \delta_i(t-1) a_{ij}] b_j(v_t)$

$\psi_j(t) = \underset{i}{\operatorname{argmax}} \delta_i(t-1) a_{ij} \rightarrow$ 最有可能的 w_{t-1}

\downarrow 值是下标

$W(t) = \underset{j}{\operatorname{argmax}} \delta_j(t)$ 从后往前 (后处理)

$w_t = \psi_{w_{t+1}}(t+1)$

小数计算很多, 别错了 (计算器)

Learning: 求 $\theta = \{A, B, \pi\}$, know V^T

$\Rightarrow \underset{\theta}{\operatorname{argmax}} P(\theta|V^T)$

前向-后向算法 (P113)

$\hat{\pi}_i / \hat{a}_{ij} / \hat{b}_{ik}$

Bayesian Belief Network

P44.

只有父子相关

联合: $P(a, b, c) = P(a|b, c) P(b|a, c) P(c)$

边缘: $P(a) = \sum_{b, c} P(a, b, c)$

条件: $P(a|b) = \frac{P(a, b)}{P(b)}$

Non-parametric

P134.

① Density estimation

求 $p(x)$ (pdf):

原理:

$P(x) \approx P = \frac{E[k]}{n} = \frac{k/n}{V}$

Parzen Windows

固定 V (参数), 求 k

$k_n = \sum_{i=1}^n \varphi(\frac{x-x_i}{h_n})$

$\Rightarrow P_n(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{V_n} \varphi(\frac{x-x_i}{h_n})$

求的相当于 $P(x|w_k)$

再用后验决策: $P(w_k|X) = \frac{P(w_k) P(X|w_k)}{P(X)}$

② P143

k_n - Nearest-Neighbor

\Rightarrow 1. 定 k_n , 在 x 中心定 V_n 直到 k_n 个样本, 返回 V_n 算 $P(w_k|X)$

$P_n(x) = \frac{k_n/n}{V_n}$

\downarrow 一类一个! $=$ 最近的 k 个样本

$P(x|w_j)$, 用 $P(w_j|X)$ 判断!

③ Decision \Rightarrow 直接估计 $P(w|X)$

\Rightarrow 最近邻 NN P146

\Rightarrow 选最近 k 个点, 其中哪个类多选哪个

复杂度 $O(nd)$

各种距离: P153

Evaluation 科:

① 列表算, 每种可能都有一项

② 后处理是求和, t 时到所有状态概率和为序列概率

先写完整公式, 再代入计算!

\downarrow 有分。

0-1	E	0:
P	P(1-P)	
独立	np	np(1-P)
均匀	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态	μ	σ^2

答题先抄算法，正则化，写样本
包括 until
还是非参数化来分类。

Linear Discriminant Function

$G(x) = w^T x + w_0$
 $= a^T y \rightarrow \begin{pmatrix} 1 \\ x \end{pmatrix}$
 (w_0)
 (w)

本质是超平面
Solution Region 是半空间交集
y 是样本
考试时都 normalize 好了 (他)

⇒ Normalize: $a^T y_i > 0 \Rightarrow$ 表示分类正确
 定义一个 \downarrow For all y_i
 半空间，交集为 solution
 ⇒ 空则线性不可分。

⇒ Method: 1) map 到高维 (线性可分) 对于 f(x) 为线性
 2) 训练求解 LDF ⇒ Alg. GD/Newton
 ☆ 最优 η (= 阶 Taylor) P185.

GD: $a = a - \eta \nabla J(a)$
 until $\eta \nabla J(a) < \epsilon$ (convergence)

Newton: $a = a - H^{-1} \nabla J(a)$
 until convergence 收敛更快

建议列表做。

⇒ Criterion Function ☆ 初始化 $k=0$

① misclassified number: $\sum_{i=1}^n |a^T y_i| \leq 0$. ($\nabla J=0$, 不可 GD)

② $J(a) = \sum_{y \in Y} (-a^T y)$, $Y = \{y_i | a^T y_i \leq 0\} \Rightarrow$ 可 GD
 $\nabla J(a) = \sum_{y \in Y} -y$ ☆ $=0$ 的也算分错了!

Batch Perceptron Alg. ⇒ 用一批错误样本来分类
 $k=k+1$
 $a = a + \eta \sum_{y \in Y_k} y \rightarrow a_k$ 错分类集合。

until $\|\eta \sum_{y \in Y_k} y\| < \epsilon$ (convergence) ⇒ 全对则 $\|\eta \sum y\| = 0$

Single-Sample Correction ⇒ 有错就立刻更新一次

$k=k+1$; $y^k = y_i$; $a = a + \eta y^k$
 until 遍历一轮后 k 不变 (没出错) Algs, $\eta=1$

Others
 $J(a) = \sum_{y \in Y} (a^T y)^2 \Rightarrow \nabla J(a) = 2 \sum_{y \in Y} a^T y y$
 $J(a) = \frac{1}{2} \sum_{y \in Y} \frac{(a^T y - b)^2}{\|y\|^2} \Rightarrow \nabla J(a) = \sum_{y \in Y} \frac{(a^T y - b) y}{\|y\|^2}$

补: variable-Increment Perceptron with Margin
 if $a^T y_i \leq b$, margin
 $k=k+1$, $y^k = y_i$, $a = a + \eta \eta y^k \Rightarrow$ 按 Alg 来, k 定后,
 until n 次一轮后 k 不变。

→ Bernoulli (单次实验) 记得要 Normalize
 b 也会反转!

Widrow-Hoff / LSE 算法
 $\Rightarrow a^T y_i > 0$ 到 $a^T y_i = b_i$

矩阵表示 $Y a = b$ (b 是 label)
 $\Rightarrow J(a) = \|Y a - b\|^2 \Rightarrow$ 使用整个数据集

MSE \downarrow
 $J(a) = \sum_{i=1}^n (a^T y_i - b_i)^2$
 $\nabla J(a) = 2 \sum_{i=1}^n (a^T y_i - b_i) y_i$
 $= 2 (Y a - b)^T Y$
 $= 2 Y^T (Y a - b)$

① Closed Form
 令 $\nabla J(a) = 0 \Rightarrow$ 要求 $Y^T Y$ 可逆。
 $\Rightarrow a = (Y^T Y)^{-1} Y^T b$

GD ($Y^T Y$ 随意) Widrow-Hoff (LSE)
 $k=k+1$
 $a = a + \eta (b_k - a^T y^k) y^k$ 对每个 y^k 随机选一个 x^m 来 BP
 每轮 check until $\eta (b_k - a^T y^k) y^k < 0$
 注意会 schedule η .
 ⇒ 随轮次 \downarrow .
 b 也会一起 normalize
 ⇒ 多分类问题
 $a \rightarrow a_i (i=1 \dots c)$
 w_i if $a_i^T y > a_j^T y$
 分类得分最高。

Kesler's Construction (P217)
 ⇒ 利用 $a_i^T y - a_j^T y > 0$
 转化为二分类问题。
 构造样本:
 每个样本构造 $c-1$ 个 $c \times d+1$ 维。
 $y_{i1}^k = \begin{bmatrix} a_{i1}^k \\ y_1^k \\ 0 \end{bmatrix}$, $y_{i2}^k = \begin{bmatrix} -a_{j1}^k \\ y_1^k \\ 0 \end{bmatrix}$
 $a^T y_{i1}^k > 0$
 $\Rightarrow w_i$ 分 $> w_j$ 分
 $\Rightarrow a^T y_{ij}^k > 0$ (for all j)
 $\Rightarrow w_i$ 为分类结果

降维技术 (P94)

① PCA

⇒ 流程:

1) $m = \frac{1}{n} \sum_{k=1}^n x_k$ 数据矩阵
 $S = \sum_{k=1}^n (x_k - m)(x_k - m)^T$

求特征根 / eigen vector,
 取前 d 个大的 value 和对应 d 个标准化的 vector

3) $W = [v_1, v_2 \dots v_d] (d \times d)$

4) $x_k' = W^T (x_k - m)$ (别忘 -m)

☆ 计算量大, 数丑, 一定按步骤来, 别急。

LDA / Fisher FDA

流程:

1) $m_i = \frac{1}{n_i} \sum_{x \in D_i} x$, $m_i = \frac{1}{n_i} \sum_{x \in D_i} x$ 类中心
 $S_B = \sum_{i=1}^c n_i (m_i - m)(m_i - m)^T$ (类间)

$S_w = \sum_{i=1}^c \sum_{x \in D_i} (x - m_i)(x - m_i)^T$ (类内)

3) 选 n 个非 0 eigen value of $[S_w^{-1} S_B]$

对应标准化 vector $[w_1, \dots, w_n]$
 ☆ $n \geq c-1$, 至多 $c-1$ 个非 0 eigen value.

4) $W = [w_1 \dots w_{c-1}]$
 $x' = W^T x$.
 $\frac{1}{2} \sum_{k=1}^c (1_k - \alpha_k)^2$
 $\frac{1}{2} \| \text{label} - \text{output} \|^2$
 Loss 用 $\frac{1}{2}$ MSE.

MLP NN.
 forward ⇒ 逐层计算
 backward ⇒ 链式法则

① Stochastic training (P239)

② Batch BP (P240)

⇒ 全部梯度累计, 再更新一次

$\Delta w = 0$
 for $x \in D$
 $\Delta w = \Delta w + \nabla J(w) \rightarrow x$ 算。
 $w = w + \Delta w$ until $\|\nabla J(w)\| < \theta$

根概率公式: 导数公式在书上。

① $P(A_1, A_2, \dots, A_n) = P(A_1) \cdot P(A_2 | A_1) \cdot P(A_3 | A_1, A_2) \dots P(A_n | A_1, \dots, A_{n-1})$

② $P(B) = \sum_{i=1}^n P(A_i) \cdot P(B | A_i)$ 可算 $P(x)$.

③ $P(A|B) = \frac{P(A, B)}{P(B)}$

统计公式:

① $E(f(x)) = \sum_{i=1}^n f(x_i) \cdot P(x_i) / \int_{-\infty}^{\infty} f(x) p(x) dx$

② $\text{Var}[x] = E[(x - E[x])^2]$
 $= \sum_{i=1}^n (x_i - \mu)^2 \cdot P(x_i) / \int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx$

矩阵: 行列式公式在书上。

① 求逆: 待定系数 $\Rightarrow 2 \times 2$ 快, 再大别

☆ 增广矩阵 + 初等行变换 $[A, I] \rightarrow [I, A^{-1}]$

② 求 Eigen value & vector

$Ax = \lambda x \Rightarrow (A - \lambda E)x = 0$
 $\Rightarrow |A - \lambda E| = 0$

列方程, 解出 $\lambda \rightarrow$ value

代入原式求 $x \rightarrow$ vector

标准化

☆ 验证!